MACHINE LEARNING — FINAL PROJECT //

זיהוי ספאם בהודעות SMS

מסווג בינארי לטקסט — Naive Bayes + TF-IDF + SMOTE

ניב ש. 9571

ליאורה ר. 9311

עידן מ. 0045

המכללה למינהל · קורס למידת מכונה · 2026

.AI tools used: Claude & ChatGPT — concept explanations and debugging only. All implementations and decisions are our own//

המשימה: סיווג ספאם בינארי

השאלה המנחה

האם ניתן ללמד מחשב להבדיל בין הודעת SMS לגיטימית להודעת ספאם — **רק על בסיס הטקסט**?

למה זה מאתגר?

- ספאם מחקה שפה טבעית — קשה להפריד
- חוסר איזון: **ham 87%** מול spam 13%
- Accuracy לבדה מטעה: מסווג שמחזיר תמיד ham מקבל 87%

דוגמת ספאם

"Free entry in 2 a wkly comp to win
"FA Cup final tkts. Text FA to 87121

spam

דוגמת Ham

"Lol now I'm after that hot
"!air balloon

ham

הנתונים: 5,574 הודעות

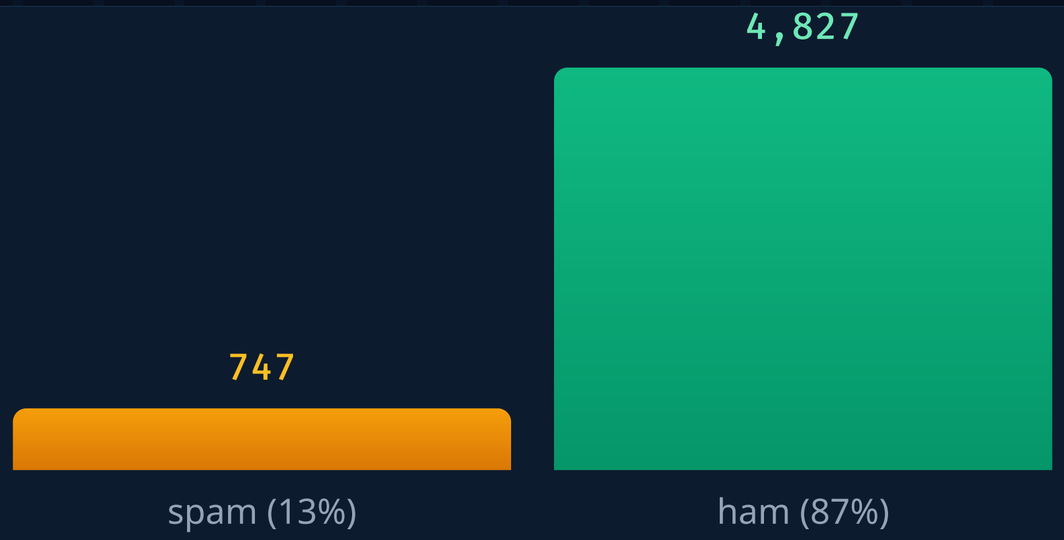

5,574
סך הודעות

4,827
ham (87%)

747
spam (13%)

פיצול Train / Test

פיצול 80/20 ידני עם `random_state=42`

4,459 הודעות לאימון · **1,115** לבדיקה

פיצול אקראי 80/20 עם random_state=42 — היחס 87/13 נשמר באופן טבעי

Source
kaggle.com / SMS Spam Collection

ייצוג הטקסט: TF-IDF + 4 פיצ'רים מהונדסים

TF-IDF — Term Frequency × Inverse Document Frequency

כל הודעה הופכת לווקטור מספרי. מילה שמופיעה הרבה **בהודעה אחת** אבל לא בשאר — מקבלת ציון גבוה.

```
TfidfVectorizer(
  max_features=3000,
  ngram_range=(1,1),
  stop_words='english'
)
```

4 פיצ'רים מהונדסים

- `unique_word_ratio` יחס מילים ייחודיות
- `has_phone` מספר טלפון בהודעה
- `has_url` קישור URL
- `currency_count` סימני מטבע (£, $)

//אינטואיציה

ספאם כמעט תמיד מכיל **טלפון, קישור, או כסף**

מה זה Naive Bayes?

הרעיון: משפט בייז

$$P(\text{spam} \mid \text{words}) = \frac{P(\text{words} \mid \text{spam}) \cdot P(\text{spam})}{P(\text{words})}$$

משווים את ההסתברות לכל מחלקה ובוחרים את הגבוהה. alpha=0.1 מוסף למניעת log(0).

למה "Naive"?

ההנחה התמימה: **כל המילים בלתי-תלויות**. בפועל לא נכון — אבל עובד מצוין על טקסט.

מימוש מאפס

```
# Training, per class:
counts = X_class.sum(axis=0) + self.alpha
self.feature_log_prob[c] =
  np.log(counts / counts.sum())

# Prediction:
score = X.dot(feature_log_prob[c])
    + class_log_prior[c]
```

סוכמים משקלי TF-IDF לכל מחלקה, מוסיפים alpha כדי למנוע log(0), ומסווגים לפי argmax.

HYPERPARAMETER TUNING — 5-FOLD CV//

Grid Search — חיפוש רשת

best mean F1 (5-fold CV)//

0.9602

tfidf_plus_ratios · alpha = 0.1

מה השתנה?

5 קבוצות פיצ'רים × 4 ערכי alpha = **20 קומבינציות**.

כל אחת הורצה ב-5-fold cross-validation.

הציון = ממוצע F1 של 5 הקיפולים.

השוואת קבוצות פיצ'רים

טיפול בחוסר איזון: SMOTE

//איך SMOTE עובד? — דוגמה

spam #1 (real)

"Free entry in 2 a wkly comp to win FA Cup final tkts. Text FA to 87121"

has_phone ✓ currency ✓

↓

spam #2 (real)

"Win £1000 cash prize! Call 09061 790 121"

has_phone ✓ currency ✓

↓

+ SMOTE interpolates +

↓

★ **ספאם סינתטי**

וקטור פיצ'רים חדש — לא הופיע בדאטה

has_phone ✓ currency ✓

↑ אותה חתימה כמו הספאמים האמיתיים

Under-sampling

הורדת דוגמאות מ-ham. מאבד מידע.

Over-sampling

שכפול דוגמאות spam. עלול לגרום ל-overfitting.

★ SMOTE

דוגמאות סינתטיות באינטרפולציה בין שכנים. **המנצח**.

mean F1 (5-fold CV)//

Original	0.9602
Under	0.9709
Over	0.9875
SMOTE ★	0.9880

+2.78% F1 רק בעזרת SMOTE

אימון סופי: Best Config על כל ה-TrainSet

2 דוגמאות דרך ה-Pipeline

"Free entry in 2 a wkly comp to win FA Cup final tkts"

`has_url=0` `currency=0` `has_phone=1`

TF-IDF → **spam** → ✓

"!Lol now I'm after that hot air balloon"

`has_url=0` `currency=0` `has_phone=0`

TF-IDF → **ham** → ✓

//הקונפיגורציה הסופית

```
features: tfidf_plus_ratios
balancing: SMOTE
model: Naive Bayes
alpha: 0.1
max_features: 3000
```

תהליך האימון

3,873 ham + ~600 spam (training set)

→ SMOTE balances to 3,873 + 3,873

→ `TfidfVectorizer.fit()` לומד אוצר מילים

→ `NaiveBayes.train()` על הדאטה המאוזן

תוצאות סופיות על Test Set

0.997	0.986	0.990	0.982
Accuracy	F1-Score	Recall	Precision

Confusion Matrix

	Predicted Spam	Predicted Ham
Actual Spam	158 TP	1 FN
Actual Ham	1 FP	955 TN

מה זה אומר?

מתוך **1,115 הודעות test** שהמודל לא ראה מעולם — רק **2 שגיאות**.

מתוך 159 הודעות ספאם אמיתיות — זיהינו 158. מתוך 956 ham — סווגו נכון 955.

2 שגיאות בלבד
מתוך 1,115

מה המודל למד?

מילות Spam מובילות

stop | mobile | urgent | call | free
claim | prize | win | txt | reply

מילות Ham מובילות

going | day | home | come | good | ok
love | time | know | later

SHAP — Mean Feature Importance

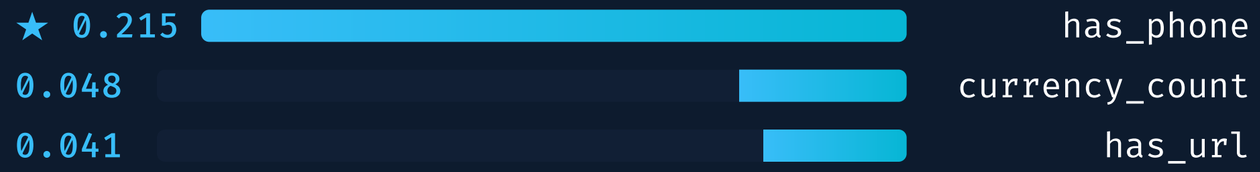

3 פיצ'רים מהונדסים
עוקפים את כל מילות ה-TF-IDF

CONCLUSIONS//

מה למדנו?

Feature Engineering > More Data

4 פיצ'רים חכמים שיפרו יותר ממאות מיצ'רים גנריים נוספים. has_phone לבדה — הפיצ'ר החזק ביותר.

Class Imbalance Matters

מ-96.0% ל-98.8% F1 רק על ידי טיפול נכון בחוסר האיזון. SMOTE לבדה הוסיפה ~3% F1.

Explainability Builds Trust

SHAP אישר שהמודל למד מהסיבות הנכונות — לא רעש. זה ההבדל בין מודל שעובד ובין מודל שאפשר לסמוך עליו.

FINAL RESULT — TEST SET//

98.6%

F1-Score

Naive Bayes + TF-IDF + SMOTE

ניב ליאורה עידן

תודה על ההקשבה!